



Vergleich dreier Implementationsvarianten für eine Analyse von Satellitenbildern

Bachelorarbeit

zur Erlangung des akademischen Grades
Bachelor of Arts (B. A.)

HUMBOLDT-UNIVERSITÄT ZU BERLIN
MATHEMATISCH-NATURWISSENSCHAFTLICHE FAKULTÄT II
INSTITUT FÜR INFORMATIK

eingereicht von: Robin Ellerkmann
geboren am: 25.04.1992
in: Berlin

Gutachter: Prof. Johann-Christoph Freytag, Ph.D.
Dipl.-Inf. Mathias Peters

eingereicht am:

verteidigt am:

Inhaltsverzeichnis

1	Einleitung	1
2	Grundlagen	3
2.1	Grundlagen der Satellitenbildanalyse	3
2.1.1	Fernerkundung mithilfe des Landsat-Satellitensystems	3
2.1.2	Aufbereitung und Analyse von Satellitenbildern	4
2.2	Parallele Datenverarbeitungssysteme	5
2.2.1	Bedeutung und Eigenschaften von Big Data	5
2.2.2	Verarbeitung großer Datenmengen - Konzepte und Systeme	6
2.2.3	Apache Flink	7
2.3	Programmierabstraktionen	9
2.3.1	Apache Flink	9
2.3.2	Python	10
3	Algorithmus zur Analyse von Pixelzeitreihen	11
3.1	Beschreibung des Algorithmus	11
3.2	Umsetzung des Algorithmus mit Apache Flink	11
3.2.1	Nutzung der Java-Programmierschnittstelle	11
3.2.2	Nutzung der Python-Programmierschnittstelle	11
3.3	Umsetzung des Algorithmus in Python	11
4	Evaluierung	13
4.1	Versuchsbeschreibung	13
4.2	Auswertung	13
5	Fazit	14

Kapitel 1

Einleitung

In den vergangenen Jahren war ein massiver Zunahme des generierten Datenaufkommens zu beobachten [EMC14]. Viele Projekte, Unternehmen und Institutionen haben Zugriff auf eine gewaltige Menge an Daten. Diese wächst immer schneller an. 2004 analysierte Google circa 100 Terabyte pro Tag [DG04]. Bis zum Jahr 2008 war die täglich zu analysierende Datenmenge bereits auf 20 Petabyte angewachsen [DG08]. Das Sloan Digital Sky Survey, das ein Viertel des Himmels astronomisch erkundet, hat seit 1998 insgesamt 116 Terabyte an astronomischen Daten gesammelt [YAJEA⁺00, AAP⁺15]. Jede Nacht kommen circa 250 Gigabyte neu hinzu [Quelle: Herr Prof. Freytags VL, dort angegebene Quelle ist offline. Wie angeben?](#). Ein weiteres Beispiel ist das 1000 Genomes Project [Bak10], das zwischen 2008 und 2013 insgesamt 464 Terabyte Daten zum menschlichen Genom sammelte. Insgesamt werden die Datenmengen weiter stark zunehmen, für das Jahr 2020 wird eine weltweites Datenaufkommen von 44 Zettabyte prognostiziert [EMC14]. Diese Entwicklung offenbart diverse neue Herausforderungen bei der Speicherung, Verarbeitung und Analyse von Daten. Dabei spielt die möglichst schnelle Verarbeitung von stetig generierten Daten eine große Rolle. Diese muss im Gegensatz zur Verarbeitung bereits gespeicherter Daten abhängig vom aktuellen Datenaufkommen skalieren. Aktuelle Datenverarbeitungssysteme wie Apache Hadoop [Foub] und Apache Flink [Foua] bieten diese Möglichkeit der Datenflussanalyse und ermöglichen eine flexible Analyse der Daten. Kern dieser Systeme ist eine Implementierung des Map-Reduce Paradigmas [DG08] sowie die Nutzung von User Defined Functions. Diese ermöglichen eine parallele Abarbeitung von Arbeitsschritten in einem direkten, azyklischen Graphen. Der DAG wird zuvor aus dem vom User bereitgestellten Quellcode erzeugt. Die durch diese Architektur erreichbare, massiv parallelisierbare Ausführung der Datenanalyse ermöglicht die Nutzung von Clustern. Somit wird eine skalierbare Infrastruktur genutzt, die wiederum eine skalierte Nutzung der Datenverarbeitungssysteme ermöglicht. Diese Systeme können auch die weiterhin wichtige Nutzung und Analyse von bereits konsistent gespeicherten Daten unter Nutzung des parallelen Verarbeitungsansatzes durchführen. Dies ist insbesondere deshalb notwendig, da traditionelle Datenbanksysteme große Datenmengen nicht immer in akzeptabler Form und Verarbeitungszeit verarbeiten können [Jac09]. Das Hauptproblem bei der Verarbeitung von großen Datenmengen auf einzelnen Maschinen entsteht, wenn die zu verarbeitende Datenmenge die Hauptspeichergröße übersteigt. In diesem Fall müssen die nicht in den Hauptspeicher speicherbaren Daten zur Verarbeitungszeit nachgeladen werden, was die Verarbeitungszeit aufgrund der unterschiedlichen Beschaffenheit der verschiedenen Speicherebenen extrem verlängert. Um diese Speicherklappe zu umgehen, werden zunehmend parallelisierbare Ansätze der Datenverarbeitung verfolgt. Im Rahmen dieser Bachelorarbeit sollen demzufolge ein traditioneller und ein massiv parallelisierbarer Ansatz bei der Verarbeitung von großen Datenmengen untersucht werden. So soll eine Abschätzung der Leistungsfähigkeit, Vorteile und Nachteile beider Ansätze ermittelt werden. Der Vergleich beider Ansätze wird am Beispiel ei-

nes Algorithmus zur Approximierung von Pixelzeitreihen durchgeführt. Dieser wird im Rahmen des Projekts GeoMultiSens[GP] zur Analyse der Veränderung der Flora in einer geographischen Region genutzt. Dabei werden durch Landsat-Satelliten Satellitenaufnahmen bereitgestellt, die nach der Aufbereitung durch vorgestellte Algorithmen ausschnittsweise untersucht werden. Nach der Analyse werden anschließend mithilfe des Algorithmus auf Basis der approximierten Werte Prognosen zur weiteren Entwicklung der Flora der untersuchten Region gestellt. Dabei werden bei einer Analyse mehrere Szenenausschnitte derselben geographischen Region analysiert. Dabei müssen große Datenmengen verarbeitet werden, so dass sich die Nutzung eines aktuellen Datenverarbeitungssystems anbietet. Bei dieser Bachelorarbeit wird als Vertreter der massiv parallelisierbaren Datenverarbeitungssysteme Apache Flink genutzt.

Es werden drei unterschiedliche Implementierungen des Algorithmus untersucht, die sich hinsichtlich der eingesetzten Technologien und Programmiersprachen unterscheiden. Die zugrunde liegende Methodik, die der Algorithmus implementiert, ist bei allen untersuchten Varianten identisch. Als Basis wird die bereits implementierte und in der Praxis genutzte Python-Implementation genutzt. Sie sollte somit die untere Schranke der Leistungsmessungen darstellen. Die zweite und dritte Variante werden in Flink implementiert. Diese beiden Varianten unterscheiden sich bezüglich der genutzten Programmiersprache. [Zur Implementierung der zweiten Variante wird Java-Schnittstelle von Flink genutzt, zur Umsetzung von Variante drei die Python-Schnittstelle.](#) Schließlich werden alle drei Varianten unter identischen Bedingungen getestet. Dies bedeutet, dass sowohl die Testumgebung als auch die Testdaten identisch sein sollen. Dabei sollen alle Varianten sowohl auf einer leistungsfähigen Einzelmaschine als auch mit einem Cluster von Maschinen getestet werden. Ausgehend von den Untersuchungen und den ermittelten Ergebnissen soll nachfolgend eine Bewertung der drei Implementierungsvarianten des Algorithmus vorgenommen werden. Dabei sollen insbesondere die Größe der Ausgangsdatenmenge, die genutzte Hardware sowie die Größe der untersuchten Bildausschnitte in Bezug zu den Ergebnissen gesetzt werden.

Kapitel 2

Grundlagen

Die Basis für die Satellitenbildanalyse mittels Apache Flink bilden zum einen Konzepte aus der Geographie, zum anderen Strukturen und Vorgehensweisen aus der Informatik. Während die geographische Komponente insbesondere bei der Aufnahme der Satellitenbilder sowie bei der inhaltlichen Konzeption der Analysen sowie der Bereinigung der Daten vertreten ist, ist die Informatik für eine technisch korrekte und effiziente Umsetzung der geographischen Konzepte verantwortlich. Nachfolgend werden zuerst die geographischen Grundlagen der Fernerkundung erläutert. Dies umfasst insbesondere die technische Spezifikation der Aufnahmegeräte der eingesetzten Satelliten sowie wichtige Verfahren zur Datenaufbereitung sowie zur Datenanalyse. Anschließend wird ein Überblick über parallele Datenverarbeitungssysteme gegeben. Dieser umfasst auch die Eigenschaften von Big Data sowie eine konzeptuelle Beschreibung der Datenanalyseplattform Apache Flink. Abschließend wird Apache Flink aus der Entwicklerperspektive betrachtet. Dabei werden insbesondere Eigenschaften der Plattform beschrieben, die bei der Entwicklung von Programmen auf Basis von Flink von Bedeutung sind. Des weiteren wird die Programmiersprache Python betrachtet.

2.1 Grundlagen der Satellitenbildanalyse

2.1.1 Fernerkundung mithilfe des Landsat-Satellitensystems

Als Fernerkundung wird „die Gesamtheit der Verfahren zur Gewinnung von Informationen über die Erdoberfläche oder anderer nicht direkt zugänglicher Objekte durch Messung und Interpretation der von ihr ausgehenden (Energie-) Felder“ [Deu12] verstanden. Fernerkundungssatelliten verfügen über verschiedene Aufnahmesysteme, die durch multispektrale Messungen von emittierter elektromagnetischer Strahlung eine berührungsfreie Beobachtung der Erdoberfläche ermöglichen. Bei der multispektralen Messung werden von Sensoren registrierte spektrale Signaturen einzelnen Bereichen des elektromagnetischen Spektrums zugeordnet. Das Resultat sind mehrere spektrumsspezifische, simultan aufgenommene Satellitenbilder, die nur das aufgefangene Licht eines spezifischen Spektralbereichs, auch Spektralband genannt, zeigen. Die Art und Qualität der Aufnahmesensoren ist dabei abhängig vom Typ des Satelliten.

Die Ausgangsdaten für die Untersuchungen in dieser Bachelorarbeit wurden von Satelliten des Landsat-Satellitensystems aufgenommen. Der erste Landsat-Satellit Landsat 1 wurde 1972 gestartet. Seitdem wurden die Sensoren und die Satelliten kontinuierlich weiterentwickelt. Aktuell sind Landsat 7 und, im Rahmen der Landsat Data Continuity Mission, Landsat 8 im Einsatz. Landsat 8 nutzt in der aktuellen Generation zwei verschiedene Instrumente zur Fernerkundung. Den Operational Land Imager (OLI) und die Thermal Infrared Sensors (TIRS).

Der OLI erfasst emittierte elektromagnetische Strahlung im Spektralbereich von 0,433 μm bis 1,390 μm unterteilt in acht Spektralkanäle sowie einen panchromatischen Kanal. Es werden mehr als 7000 Detektoren pro Spektralband genutzt, um eine bessere Bildqualität zu bieten als frühere Systeme [MSWI04]. Neben den klassischen Farbspektren Blau, Grün und Rot nutzt Landsat-8 ein weiteres Band, das speziell für die Fernerkundung von Küsten genutzt wird. Außerdem verfügt Landsat-8 über drei Infrarotbänder, die nahes und mittleres Infrarotlicht registrieren, sowie ein weiteres Infrarotband, das auf die Beobachtung von Cirruswolken spezialisiert ist. Der panchromatische Kanal registriert elektromagnetische Strahlung mit Wellenlängen von 0,500 μm bis 0,680 μm . Dieser Spektralbereich entspricht etwa dem des menschlichen Auges. Aufgrund des, im Vergleich zu den einzelnen Farbfrequenzbändern, breiten abgedeckten Spektralbereichs ist eine höhere Auflösung der Bilder möglich.

Die Thermal Infrared Sensors (TIRS) [Cha11] umfassen zwei Thermalkanäle. Diese erfassen im Gegensatz zu den Multispektralkanälen elektromagnetische Emissionen mit Wellenlängen zwischen 10,30 μm und 12,50 μm , also langwellige Infrarotstrahlung. Dies ist insbesondere für die Beobachtung von Wolken nützlich. Die Kantenlänge der einzelnen Pixel beträgt 100 Meter. Diese kann nachträglich auf 30 Meter angeglichen werden, um eine bessere Kompatibilität mit den Aufnahmen der Multispektralbänder zu gewährleisten.

Landsat 8 sendet pro Tag 400 Aufnahmen der Erdoberfläche, auch Szenen genannt, an die Bodenstation. Eine Aufnahme zeigt dabei eine geographische Region der Erde mit einer Ost-West-Ausdehnung von 185 Kilometer. Dies entspricht 100 nautischen Meilen. Die Nord-Süd-Ausdehnung einer Szene beträgt circa 174 Kilometer

Durchschnittlich wird jede Region der Erde alle 16 (?) Tage überflogen [IDB12].

Die von Landsat-Satelliten aufgezeichneten und übermittelten Bilder müssen jedoch vor der Durchführung von Analysen aufbereitet werden.

2.1.2 Aufbereitung und Analyse von Satellitenbildern

Die durch die Landsat-Satelliten aufgezeichneten und an die Bodenstationen übermittelten Szenen müssen vor ihrer Nutzung aufbereitet werden. Dadurch wird im Allgemeinen die Bildqualität verbessert, da externe Störfaktoren und eventuelle interne Fehlfunktionen ausgeglichen werden können. Es wird zwischen radiometrischen und die geometrischen Aufbereitungen unterschieden. Bei der radiometrischen Aufarbeitung werden digitale Werte wie zum Beispiel die Helligkeit der Szene angepasst.

Im Rahmen der geometrischen Aufbereitung sollen die Folgen einer eventuellen Fehlpositionierung des Satelliten korrigiert werden. Um die Szenen sinnvoll analysieren zu können, müssen sie korrekt und genau positioniert sein. Dies gilt insbesondere bei der Analyse einer Serie von Szenen derselben geographischen Region. Um eine normierte Positionierung der Szenen zu schaffen, werden aus jeder Szene, die einen Teil der zu analysierenden geographischen Region beinhaltet, quadratische Teile der Originalszene ausgeschnitten. Diese ausgeschnittenen Bereiche der ursprünglichen Szene werden Kacheln genannt. Dann wird jeder Pixel der Kachel auf die Zugehörigkeit zum Zielgebiet geprüft. Wenn ein Pixel relevant ist, wird er anhand seiner, aus der Position des Satelliten zum Aufnahmezeitpunkt ermittelten, Position in einem finalen Bild hinzugefügt. Dies garantiert eine einheitliche Grundlage für die Analyse der Zielregion.

Zusätzlich zu Fehlpositionierungen des Satelliten und den sich daraus ergebenden Abweichungen müssen möglicherweise noch weitere Störfaktoren durch die Aufbereitung gemindert werden. Hierzu zählen zum Beispiel durch die Atmosphäre verursachte Verschlechterungen, die aus Interferenzen innerhalb der Atmosphäre zwischen Erdoberfläche und dem Satelliten resultieren. Diese sollen korrigiert werden, um ein genaueres Satellitenbild zu erhalten. Techniken um diese Verbesserung zu erreichen sind beispielsweise das Strahlungstransfermodell, die bildbasierte atmosphärische Korrektur und die Histogramm-Minimum-Methode. Es ist individuell von der Szene und den zur

Verfügung stehenden Metadaten abhängig, mit welcher Methode die nützlichste Verbesserung erreicht werden kann.

Die Aufbereitung von Satellitenbildern muss vor einer wissenschaftlichen Analyse erfolgen, damit die Szenen unabhängig von Witterungseinflüssen, Atmosphäreninterferenzen, Fehlpositionierungen und sonstiger Störfaktoren untersucht werden können. Durch die zunehmend bessere Qualität von Satellitenbildern, die durch Fernerkundungssatelliten aufgezeichnet werden [MSWI04], können detailliertere Analysen getätigt werden. Jedoch steigt mit zunehmender Größe der Bilddateien auch der Rechenaufwand, um die Szenen aufzubereiten und zu analysieren. Mit zunehmender Datenmenge wird eine massiv parallelisierbare Vorgehensweise bei der Aufbereitung und der Analyse von Satellitenbildern attraktiver. Denn verteilte Systeme lassen sich meist kostengünstiger und flexibler erweitern als einzelne Maschinen, so dass das System bei einer unerwartet großen Datenmenge schnell erweitert werden kann. Dadurch lässt sich eine schnellere Ausführung der Prozesse erreichen.

2.2 Parallele Datenverarbeitungssysteme

Seit mehreren Jahren ist ein massiver Anstieg der global produzierten Datenmengen zu beobachten [EMC14]. Diese Menge an Daten mithilfe traditioneller Methoden der sequentiellen, stapelweisen Datenverarbeitung nicht effektiv zu verarbeiten. Aus diesem Grund wird eine verteilte Verarbeitung von Daten in vielen Bereichen zunehmend populär. Dies gilt insbesondere für Daten, die gemäß der in Sektion 2.2.1 beschriebenen Kriterien als Big Data klassifiziert werden. Um eine parallele Verarbeitung von Big Data zu ermöglichen, wurden bestehende parallele Datenverarbeitungsmechanismen erweitert. Insbesondere das Map-Reduce Paradigma [DG04] bewirkte eine grundlegende Veränderung bei der Vorgehensweise zur Verarbeitung großer Datenmengen. In der Folge wurde Map-Reduce erweitert und flexibler einsetzbar. Außerdem wurden auch andere Vorgehensweisen evaluiert. Diese Entwicklung wird in Sektion 2.2.2 erläutert. Eines der Systeme auf Basis von Map-Reduce ist Apache Flink [Foua]. Es ermöglicht eine massiv parallelisierbare Verarbeitung von großen Datenmengen. Die konzeptionelle Struktur von Apache Flink wird in Sektion 2.2.3 beschrieben.

2.2.1 Bedeutung und Eigenschaften von Big Data

Zusätzlich zu der schnell wachsenden Menge an verfügbaren Daten wächst der Bedarf diese nutzbringend zu analysieren. Insbesondere Forschungseinrichtungen sowie Unternehmen besitzen beziehungsweise produzieren eine immer umfangreichere Menge an Daten. Beispiele sind unter anderem das Sloan Digital Sky Survey, das seit 1998 insgesamt 116 Terabyte an astronomischen Daten gesammelt hat [YAJEA⁺00, AAP⁺15] und das 1000 Genomes Project [Bak10], das zwischen 2008 und 2013 insgesamt 464 Terabyte Daten zum menschlichen Genom sammelte. Weitere Beispiele sind das CERN, dessen Large Hadron Collider täglich circa 1 Petabyte Daten produziert, und Google, das bereits im Jahr 2008 rund 20 Petabyte Daten pro Tag verarbeitete [DG08]. Diese Beispiele verdeutlichen den Trend, dass immer mehr Daten generiert und gespeichert werden, in der Hoffnung diese sinnvoll nutzen zu können. Diese Entwicklung wird sich vermutlich weiter fortsetzen, so wird im Jahr 2020 ein weltweites Datenaufkommen von 44 Zettabyte prognostiziert [EMC14]. Um jedoch einen Nutzen aus den gesammelten Daten zu generieren, müssen diese analysiert werden. Aufgrund der Menge der zu verarbeitenden Daten reichen traditionelle Methoden der Datenanalyse nicht immer aus, um die Daten auszuwerten.

Zusätzlich existieren neben der Größe einer Datenmenge noch weitere wichtige Eigenschaften, die die Verarbeitung mittels traditioneller Methoden erschweren. Insbesondere die drei Charakteristika Volumen (*volume*), Komplexität (*variety*) sowie die echtzeitnahe Verfügbarkeit und schnelle

Verarbeitung (*velocity*) von Daten, die bereits 2001 von Dick Laney beschrieben [Lan01] wurden, sind weitere wichtige Eigenschaften solcher Daten. 2004 wurde außerdem die nicht garantierte Zuverlässigkeit und Einheitlichkeit der Daten (engl. *veracity*) ergänzt [ZdP⁺12]. Daten, die diese Eigenschaften aufweisen werden Big Data genannt. Im folgenden werden die vier Eigenschaften kurz erläutert.

Volumen. Das Volumen einer Datenmenge ist das augenscheinlich prägendste der vier Attribute. Wie bereits erwähnt, zeigen viele Beispiele, dass die zu verarbeitenden Datenmengen stark ansteigen. In der Folge entstehen neue Anforderungen bei der Speicherung und Verarbeitung der Daten. Zum einen ist eine möglichst effiziente Nutzung von Speicherplatz nötig, zum anderen müssen die Strukturen zur Verarbeitung der Daten auf die aktuellen Datengrößen angepasst werden. Des weiteren ist die Größe der zu verarbeitenden Daten der Grund für die notwendige Parallelisierung des Verarbeitungsprozesses, da sequentiell arbeitende Verfahren nicht leistungsfähig genug sind, um Datenmengen in der in den Beispielen aufgezeigten Größenordnung zu verarbeiten. Des weiteren lassen sich nur parallelisierte Rechnerstrukturen flexibel skalieren.

Komplexität. Erhobene Daten weisen vielfältige Datenstrukturen auf. Neben Rohdaten werden auch semistrukturierte und strukturierte Daten gesammelt. Zusätzlich ist auch eine vorliegende Datenstruktur aufgrund von Inkompatibilität mit anderen Datenstrukturen möglicherweise schwierig in Bezug zu anderen Daten zu bringen. Ein Grund dafür ist der massive Anstieg an unterschiedlichen Datenquellen, deren erhobene Daten nicht immer aufeinander abgestimmt sind. Daraus können sich Herausforderungen bei der Normierung von Daten ergeben. Darüber hinaus sind möglicherweise auch Datensemantiken inkonsistent.

Echtzeitnahe Verarbeitung. Anwendungsfälle, die eine echtzeitnahe Verarbeitung von großen Datenmengen fordern, werden immer zahlreicher. [Mehr schreiben](#)

Zuverlässigkeit. Aufgrund des massiven Anstiegs an Datenquellen wird es schwieriger die Echtheit und Korrektheit von zu analysierenden Daten zu kontrollieren. Es ist jedoch essentiell für die Korrektheit jeder Analyse, dass ihre Grundlage korrekt ist. Insofern müssen Möglichkeiten gefunden werden die Korrektheit von Daten automatisiert zu prüfen.

Um Big Data verarbeiten zu können, wurden in den letzten Jahren immer wieder neue Konzepte und Systeme entwickelt, die die spezifischen Charakteristika von Big Data berücksichtigen.

2.2.2 Verarbeitung großer Datenmengen - Konzepte und Systeme

Die Verarbeitung von Big Data unterscheidet sich sowohl konzeptionell als auch in der technischen Umsetzung massiv von der Verarbeitung anderer Daten. Dies liegt vor allem darin begründet, dass traditionelle Konzepte und Techniken wie sequentiell arbeitende Algorithmen und transaktionsbasierte Datenbanksysteme nicht parallelisiert verwendet werden können. In Anbetracht des steigenden Bedarfs an Techniken, mit deren Hilfe Big Data verarbeitet werden können, wurden die Entwicklung neuer und die Weiterentwicklung bestehender Technologien und Konzepte im Bereich Big Data innerhalb der letzten Jahre massiv forciert [Quelle](#). Dazu zählen insbesondere massiv parallelisierbare Rechnerstrukturen in Verbindung mit neuartigen Datenverarbeitungssystemen, die diese Konzepte und Technologien verwenden um Big Data verarbeiten zu können.

Die Entwicklung paralleler Rechnerstrukturen begann in den 1970er Jahren im Rahmen der Konstruktion von Computern mit mehreren kleinen Prozessoren (*Computer with multiple miniprocessors*) [Bel71, WB72]. Die Entwicklung nutzbarer parallel arbeitender Computer begann in den 1980er Jahren [Sei85]. Hinzu kam die Konzeption und Umsetzung parallelisiert konzipierter Algorithmen [BH85]. Seitdem schritt die Weiterentwicklung parallelisierter Architekturen und Konzepte mit steigendem Tempo fort [TW12]. Während früher einzelne Maschinen mit parallel geschalteten Komponenten zur Bearbeitung aufwändiger Datenverarbeitungsaufgaben eingesetzt wurden, werden aktuell vermehrt Computercluster eingesetzt. Diese bestehen aus mehreren Maschinen, die mithilfe eines losen Netzwerks verbunden sind und so einen virtuellen Supercomputer

darstellen [HDF13]. Aufgrund der Beschaffenheit der Computercluster lässt sich die Anzahl an zusammengeschlossenen Maschinen flexibel definieren. Auf diese Weise kann die Rechenleistung eines solchen Netzwerks kontinuierlich an die Anforderungen angepasst werden. Dies schafft optimale Voraussetzungen für die Verarbeitung von Big Data. So ist beispielsweise eine echtzeitnahe Verarbeitung von Daten möglich, selbst wenn die zu verarbeitende Datenmenge plötzlich massiv ansteigt. In diesem Fall werden lediglich weitere Maschinen an das Cluster angeschlossen und auf diese Weise die Rechenleistung sprunghaft erhöht. Um diese physischen Strukturen nutzen zu können, müssen jedoch auch die der Verarbeitung zugrunde liegenden Algorithmen parallel verarbeitbar implementiert sein. Ein prägendes Konzept, das diese Implementation ermöglicht, ist das 2004 veröffentlichte Map-Reduce Paradigma [DG04]. Es ermöglicht die nebenläufige Berechnung von sehr großen Datenmengen sowie eine selbstständige Korrektur von bei Ausfällen von Netzwerk-knoten verlorenen Daten. Dabei nutzt es oben beschriebene Computercluster. Seit 2004 wurde das Map-Reduce Paradigma erweitert und bietet nun mehr Flexibilität. Aufgrund des Einsatzes von Map-Reduce in Hadoop [Foub] und anderen Systemen bleibt es aber eines der dominanten Paradigmen bei der Verarbeitung großer Datenmengen. Auch Apache Flink [Foua] nutzt eine ähnliche Grundfunktionsweise, um die parallelisierten Datenströme zu verwalten.

In Anbetracht der Unterschiede der Eigenschaften von Big Data und traditionellen Daten sind bisherige Datenbankstrukturen wie zum Beispiel relationale Datenbanken nicht in der Lage, alle Ansprüche an ein modernes Datenbankmanagementsystem zu erfüllen. Insbesondere die unzureichende Skalierbarkeit relationaler Datenbanken bei großen Datenmengen, speziell auf verteilten Systemen, sowie die Notwendigkeit der Einheitlichkeit der zu speichernden Daten verhindern eine effiziente Speicherung von großen und nicht einheitlichen Datenmengen [MH13]. Als Alternative wurden NoSQL-Datenbankstrukturen konzipiert. Während relationale Datenbanken meist die AKID-Eigenschaften Atomarität, Konsistenz, Isolation und Dauerhaftigkeit [HR83] erfüllen, sind diese bei NoSQL-Datenbanksysteme nicht im gleichen Maße umsetzbar. Dies wird durch das CAP-Theorem [Bre00] verdeutlicht. Es besagt, dass ein verteiltes System nur zwei der drei Eigenschaften Konsistenz (*Consistency*), Verfügbarkeit (*Availability*) und Partitionstoleranz (*Tolerance to network partitions*) zur gleichen Zeit besitzen kann. Dies führt dazu, dass bei der Nutzung verteilter Systeme, beispielsweise in Verbindung mit einem NoSQL-Datenbanksystemen, der Fokus auf zwei dieser drei Charakteristika gesetzt werden muss, während die dritte Eigenschaft vernachlässigt werden muss. Einige Beispiele von Implementierungen verschiedener Kombinationen von Eigenschaften im Rahmen des CAP-Theorems sind in [Aba09] beschrieben. NoSQL-Datenbanken werden bereits in Verbindung mit Plattformen wie Apache Hadoop [Foub] und Apache Flink [Foua] genutzt, um Big Data angemessen zu speichern [Quelle](#).

Darüber hinaus müssen jedoch neue Vorgehensweisen bei der Prozessierung von Big Data angewendet werden. Insbesondere die mangelnde Parallelisierbarkeit sequentiell arbeitender Systeme macht traditionelle Systeme ungeeignet, um große Datenmengen in angemessener Zeit zu verarbeiten. Außerdem sind sie nicht flexibel genug skalierbar, um ein stark steigendes Datenaufkommen zu verarbeiten. Ein Konzept, das eine parallelisierte Verarbeitung von Daten ermöglicht ist Map-Reduce.

Alternativen zu MR

Eigenschaften von Systemen

Innerhalb der letzten zehn Jahre wurden diverse Systeme zur Verarbeitung großer Datenmengen auf verteilten Systemen entwickelt. Neben den bereits erwähnten Systemen Apache Hadoop und Apache Flink existieren weitere populäre Systeme wie Apache Spark [Quelle Spark Website](#), Apache Storm [Quelle Storm Website](#) oder Asterix [?].

2.2.3 Apache Flink

Ein Datenverarbeitungssystem, das auf eine massiv parallelisierte Verarbeitung von großen Datenmengen spezialisiert ist, ist Apache Flink. Es ging 2014 [Quelle] aus Stratosphere hervor, das seit 2010 kooperativ von Forschern verschiedener Universitäten entwickelt wurde [BEH⁺10, ABE⁺14]. Seit Januar 2015 ist Apache Flink ein Top-Level Projekt der Apache Software Foundation [Fou15], was eine sich seitdem stark vergrößernde Nutzerschaft zur Folge hat. Flink unterscheidet dabei in zwei Arten der Dateneingabe. Zum einen ist es möglich Daten in Echtzeit einzulesen und zu verarbeiten (*Stream Processing*), zum anderen können gespeicherte Daten genutzt werden (*Batch Processing*).

Die Hauptkomponenten der Plattform sind die Flink-Laufzeitumgebung (*Flink Runtime*) und der Flink-Optimierer (*Flink Optimizer*). Der Flink-Optimierer erhält einen mithilfe einer Programmierschnittstelle spezifizierten Datenflussgraph als Eingabe. Dieser ist ein gerichteter azyklischer Graph, dessen Knoten Flink-Operatoren repräsentieren. Der Datenflussgraph wird vom Flink-Optimierer in einen weiteren gerichteten azyklischen Graphen umgewandelt, den sogenannten *Jobgraph*. **Wie wird er optimiert? Wie viele Details sind nötig?** Dieser optimierte Datenflussgraph besteht aus mehreren, teilweise unabhängig voneinander zu verarbeitenden Arbeitsschritten. Jeder Arbeitsschritt erhält dabei einen Datenstrom als Eingabe und produziert einen weiteren Datenstrom als Ausgabe. Die Arbeitsschritte bilden also die Knoten des Jobgraphs, während die Kanten Datenströme darstellen. Die verschiedenen Elemente des Jobgraphs können aufgrund seiner Struktur teilweise parallel bearbeitet werden. Die Flink-Runtime wurde früher unter dem Namen Nephelie entwickelt [WK09]. Ihre Aufgabe ist die effiziente Organisation der Ausführung der einzelnen Arbeitsschritte. Sie verteilt die einzelnen Arbeitsschritte gemäß ihrer Abfolge im Jobgraph an die einzelnen Knoten des Netzwerkes, auf dem die Flink-Anwendung ausgeführt wird.

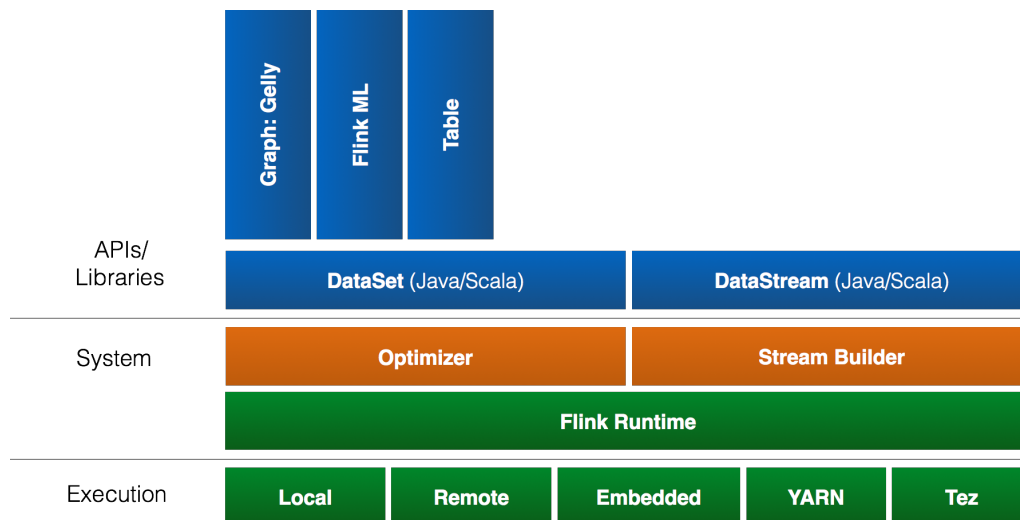


Abbildung 2.1: Übersicht der wichtigsten Systemkomponenten von Flink

Ein solches Netzwerk besteht dabei aus zwei verschiedenen Klassen von Knoten. Einen Master-Knoten, auch *Jobmanager* genannt, sowie eine individuell festlegbare Anzahl an Worker-Knoten. Der Jobmanager erhält den Jobgraph als initiale Eingabe. Dieser wird in einen parallel strukturierten *ExecutionGraph* transformiert. Für jeden Knoten des Jobgraphs wird ein *ExecutionJobVertex* erstellt. Dieser verantwortet die Ausführung des durch den Knoten repräsentierten Operators und die Weitergabe der, aus der Anwendung des Operators auf die Eingabedaten des Operators

resultierenden, Zwischenergebnisse. Dabei werden n *ExecutionVertices* genutzt, wobei n dem festgelegten Grad der Parallelität entspricht. Jeder *ExecutionVertex* übernimmt dann die Ausführung einer der parallelisierten Verarbeitungsinstanzen des Operators. Dazu wird ein Worker-Knoten genutzt. Der *ExecutionJobVertex* garantiert die komplette Ausführung des Operators auf der gesamten Eingabedatenmenge, indem der Status jedes *ExecutionVertex* verfolgt wird. Sollte einer der *ExecutionVertices* ausfallen wird die gerade verarbeitete Ausführungsinstanz an andere *ExecutionVertices* delegiert. Darüber hinaus beinhaltet der *ExecutionGraph* die Zwischenergebnisse, die zwischen der Anwendung verschiedener Operatoren erstellt werden. Dadurch ist jederzeit bekannt, ob die Bedingungen für die Ausführung eines weiteren Operators gegeben ist, oder ob noch nicht alle Eingabedaten in Form von Zwischenergebnissen verfügbar sind.

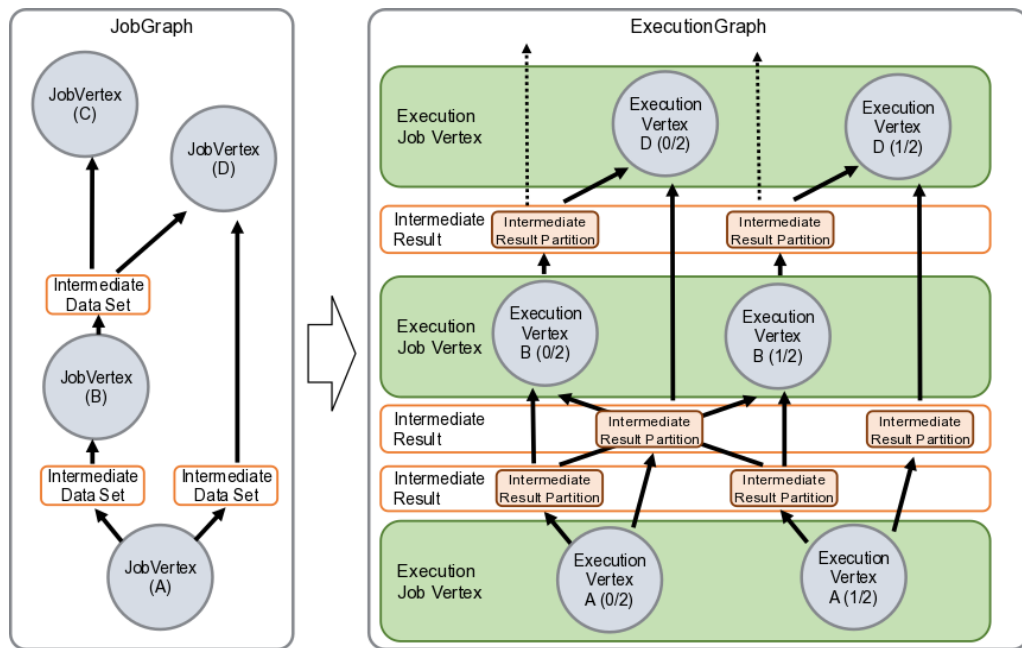


Abbildung 2.2: Modell eines Jobgraphs und des dazugehörigen ExecutionGraphs

Ähnlich wie andere Big-Data-Plattformen wird Flink in einer eigenen *Java Virtual Machine* ausgeführt. Als Konsequenz hieraus ergibt sich die Herausforderung große Datenmengen innerhalb dieser virtuellen Maschine effizient zu speichern und zu verwalten. Flink verfügt über eine eigene Speicherverwaltung, die von Datenbank-Management-Systemen entlehnte Technologien und das Map-Reduce Paradigma kombiniert. Sie besitzt eine fest definierte Anzahl, in der Regel 70% des verfügbaren Speichers der virtuellen Maschine, an vorbelegten Speicherbereichen, die *MemorySegment* genannt werden und vom *MemoryManager* verwaltet werden. Jeder Speicherbereich besitzt ein reguläres, 32 Kilobyte großes Java Byte-Array, auf das mithilfe unsicherer Java-Methoden zugegriffen wird. Durch die Nutzung der unsicheren Java-Methoden werden die sonst üblichen Kontrollmechanismen umgangen, um eine effizientere Ausführung zu ermöglichen. Darüber hinaus sind die Speicherbereiche erneut nutzbar, ohne dass der Speicher neu zugewiesen werden muss. Somit sinkt der Bedarf für eine automatische Speicherbereinigung massiv. Damit die Daten in einem *MemorySegment* gespeichert werden können, müssen sie als binäre Datenrepräsentation vorliegen. Um auch nicht binäre Daten speichern zu können verwendet Flink ein eigenes Serialisierungssystem. Mit dessen Hilfe lässt sich die binäre Repräsentation der Daten bestimmen. Flinks Serialisierung von Daten ist vom jeweiligen Datentyp abhängig. Idealerweise werden jedem Objekt

map	Def map
reduce	Def reduce
filter	Der <i>filter</i> -Operator prüft jedes Element eines DataSets auf eine nutzdefinierte, binär auswertbare <i>filter</i> -Bedingung. Alle Elemente, auf die diese Bedingung nicht zutrifft, werden aus dem DataSet entfernt.
join	def join
union	def union

Tabelle 2.1: Wichtige Operatoren in Apache Flink

Informationen zum Datentyp angefügt. Die intern binäre Repräsentation der Daten ermöglicht es Flink Datentransformationen schneller und effizienter umzusetzen. Dies ermöglicht eine effiziente Implementierung von oft genutzten Operatoren wie zum Beispiel *map* und *reduce*, da diese mit Blöcken arbeiten, die der Größe der MemorySegments entsprechen. Auf diese Weise wird der Aufwand des *Garbage Collectings* stark reduziert, was die Ausführungszeit massiv verringert [Hü15].

2.3 Programmierabstraktionen

2.3.1 Apache Flink

Da Apache Flink das Map-Reduce Paradigma erweitert, bestehen auch Flink-Programme aus Datenquellen, Datensenzen sowie Operatoren. Aus diese wird ein gerichteter, azyklischer Graph erzeugt, dessen Kanten gerichtete Datenströme darstellen. Dieser DAG ist der 2.2 beschriebene Jobgraph und wird entsprechend verarbeitet. Operatoren sind in Flink als Funktionen zweiter Ordnung definiert, die jeweils um eine *User-defined function* erweitert werden. Jeder Operator benötigt mindestens eine Datenmenge in Form eines *DataSet* als Eingabe, die mithilfe des Operators transformiert wird. Dabei ist jede Funktion zweiter Ordnung eine innerhalb des Systems definierte Variante, die Eingabedaten des Operators in Gruppen aufzuteilen. Eine UDF hingegen lässt sich individuell implementieren. Sie erhält jeweils eine durch die Funktion erster Ordnung definierte Gruppe von Daten als Eingabe und ermöglicht die Manipulation dieser Daten. Sowohl die Anzahl der Eingabedatensätze als auch die Anzahl der Ausgabedatensätze kann abhängig von der verwendeten Funktion erster Ordnung variieren. Die Verarbeitung des Operators wird gruppenweise ausgeführt, so dass jeder Knoten des genutzten Netzwerks eine Abfolge von Gruppen verarbeitet. Während der Bearbeitung dieser Gruppen erfolgt keine Kommunikation mit anderen Knoten, so dass nur eine möglicherweise vorhandene Ausgabedatenmenge an andere Knoten des Netzwerkes weitergegeben werden kann. Flink umfasst zum Zeitpunkt des Erstellens dieser Arbeit 18 Operatoren. Darunter befinden sich unter anderem die Operatoren *map*, *reduce*, die bereits bei der Entwicklung des Map-Reduce Paradigmas genutzt wurden. Diese und weitere Operatoren sind in [Figure xx](#) definiert.

Apache Flink erweitert dabei das Map-Reduce Paradigma um weitere Operatoren.

2.3.2 Python

Python ist eine quelloffene und universell einsetzbare Programmiersprache, die seit 1989 existiert und fortwährend weiter entwickelt wird. Prägende Eigenschaften der Sprache sind unter anderem eine dynamische Typisierung von Variablen, eine simpel gehaltene Syntax und die Erweiterbarkeit durch Module und Bibliotheken. Es ist auch möglich Python-Code durch C- beziehungsweise C++-Bibliotheken zu erweitern [Mar06]. Dies ermöglicht eine verkürzte Ausführungszeit eines Programms, insbesondere bei rechenintensiven Programmabschnitten. Ein Schwachpunkt von Python

im Bezug auf die schnelle Verarbeitung großer Datenmengen ist die nicht auf automatisierte Parallelisierung ausgelegte Architektur. Daraus resultiert eine unzureichende Skalierbarkeit, sobald Daten, deren Größe die Arbeitsspeichergröße der ausführenden Maschine übersteigt, verarbeitet werden müssen. Dies ist insbesondere im Zuge der oben aufgezeigten Entwicklung hin zu größeren zu verarbeitenden Datenmengen relevant. Entwicklungen, die eine bessere Parallelisierung und damit einhergehend eine bessere Skalierbarkeit von Python Projekten zum Ziel haben, sind jedoch meist nicht universal anwendbar. Darüber hinaus wird die Funktionalität dieser Ansätze durch Module bereitgestellt und existiert somit nicht als Grundfunktion in Python sondern muss projektweise hinzugefügt werden. Dies erhöht den zu leistenden Anpassungs- und Entwicklungsaufwand im Vergleich zu anderen Systemen, die mit Rücksicht auf diese Anwendungsfälle konzipiert wurden.

Kapitel 3

Beschreibung und Umsetzung des Algorithmus zur Analyse von Pixelzeitreihen

3.1 Beschreibung des Algorithmus zur Analyse von Pixelzeitreihen

Beschreibung der Vorgehensweise bei der Analyse (Zhu, SVR), Ziel der Analyse, Entwicklungsgeschichte der Analysetechnik

3.2 Umsetzung des Algorithmus mit Apache Flink

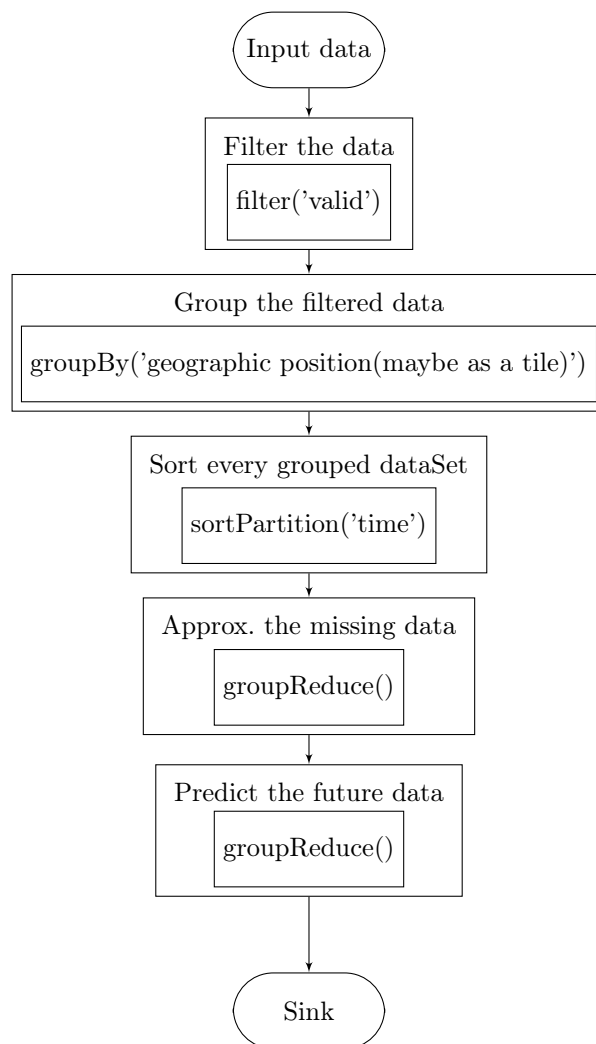
3.2.1 Nutzung der Java-Programmierschnittstelle

3.2.2 Nutzung der Python-Programmierschnittstelle

3.3 Umsetzung des Algorithmus in Python

Die Analyse von Satellitenbildern erfordert die Verarbeitung großer Mengen komplexer Rohdaten, **die nahezu in Echtzeit verfügbar sind**. Aufgrund dieser Charakteristika handelt es sich bei dieser Analyse um ein **Big-Data Problem**. Denn alle vier Kriterien, die ein solches charakterisieren sind erfüllt.

Bei der Analyse von Satellitenbildern sind die Merkmale Datengröße und Datenkomplexität sowie die schnelle Verarbeitung der Daten von Bedeutung. Abhängig von der Anzahl der genutzten Bilder sind die zu verarbeitenden Datenmengen sehr groß. Ein Bild besitzt im Regelfall abhängig vom Satellitenmodell, das die Aufnahme gemacht hat, eine Größe von 750 Megabyte bis zu 1,5 Gigabyte. Um eine Entwicklung zu untersuchen werden jedoch viele dieser Bilder in die Untersuchung mit einbezogen, so dass die zu verarbeitende Datenmenge kontinuierlich ansteigt. Dieser kontinuierliche Anstieg entsteht dadurch, dass aktuell mehrere Satelliten mit der Fernerkundung der Erde fortfahren und so in kurzen Intervallen neue Bilder zur Verfügung stehen, die im Rahmen der Analyse verwendet werden sollen. **Quelle**.



Kapitel 4

Evaluierung

4.1 Versuchsbeschreibung

Beschreibung + Begründung für meine Versuchsbedingungen

4.2 Auswertung

Beschreibung und Bewertung der Ergebnisse meiner Untersuchungen

Kapitel 5

Fazit

Fazit und Ausblick z.b. Vergleich mit anderen Untersuchungen

Literaturverzeichnis

- [AAP⁺15] Shadab Alam, Franco D. Albareti, Carlos Allende Prieto, F. Anders, Scott F. Anderson, Timothy Anderton, Brett H. Andrews, Eric Armengaud, Áric Aubourg, Stephen Bailey, and et al. The eleventh AND twelfth data releases of the sloan digital sky survey: Final data from sdss-iii. *The Astrophysical Journal Supplement Series*, 219(1):12, Jul 2015.
- [Aba09] Daniel J Abadi. Data management in the cloud: Limitations and opportunities. *IEEE Data Eng. Bull.*, 32(1):3–12, 2009.
- [ABE⁺14] Alexander Alexandrov, Rico Bergmann, Stephan Ewen, Johann-Christoph Freytag, Fabian Hueske, Arvid Heise, Odej Kao, Marcus Leich, Ulf Leser, Volker Markl, and et al. The stratosphere platform for big data analytics. *The VLDB Journal*, 23(6):939,964, May 2014.
- [Bak10] Monya Baker. Next-generation sequencing: adjusting to data overload. *Nat Meth*, 7(7):495,Äi499, Jul 2010.
- [BEH⁺10] Dominic Battré, Stephan Ewen, Fabian Hueske, Odej Kao, Volker Markl, and Daniel Warneke. Nephele/pacts: a programming model and execution framework for web-scale analytical processing. In *Proceedings of the 1st ACM symposium on Cloud computing*, pages 119–130. ACM, 2010.
- [Bel71] C Gordon Bell. C. mmp: the cmu multiminiprocessor computer, requirements and overview of the initial design. 1971.
- [BH85] A. Borodin and J.E. Hopcroft. Routing, merging, and sorting on parallel models of computation. *Journal of Computer and System Sciences*, 30(1):130,Äi145, Feb 1985.
- [Bre00] Eric Brewer. Towards robust distributed systems. 07 2000.
- [Cha11] Anju Chaudhary. Thermal infrared sensors. *Encyclopedia of Snow, Ice and Glaciers*, page 1156, 2011.
- [Deu12] Deutsches Institut für Normung e.V. *Photogrammetrie und Fernerkundung - Begriffe*, 8 2012. Rev. 3.
- [DG04] Jeffrey Dean and Sanjay Ghemawat. Mapreduce: Simplified data processing on large clusters. page 13, 2004.
- [DG08] Jeffrey Dean and Sanjay Ghemawat. Mapreduce. *Communications of the ACM*, 51(1):107, Jan 2008.
- [EMC14] EMC². The digital universe of opportunities. Technical report, EMC², 2014.

- [Foua] Apache Software Foundation. Flink website. <https://flink.apache.org/>.
- [Foub] Apache Software Foundation. Hadoop website. <https://hadoop.apache.org/>.
- [Fou15] Apache Software Foundation. The apache software foundation announces apache™ flink™ as a top-level project. https://blogs.apache.org/foundation/entry/the_apache_software_foundation_announces69, January 2015.
- [GP] GfZ-Potsdam. Geomultisens website. <http://www.geomultisens.gfz-potsdam.de/>.
- [HDF13] Kai Hwang, Jack Dongarra, and Geoffrey C Fox. *Distributed and cloud computing: from parallel processing to the internet of things*. Morgan Kaufmann, 2013.
- [HR83] Theo Haerder and Andreas Reuter. Principles of transaction-oriented database recovery. *ACM Computing Surveys (CSUR)*, 15(4):287–317, 1983.
- [Hü15] Fabian Hüske. Juggling with bits and bytes. <https://flink.apache.org/news/2015/05/11/Juggling-with-Bits-and-Bytes.html>, May 2015.
- [IDB12] James R. Irons, John L. Dwyer, and Julia A. Barsi. The next landsat satellite: The landsat data continuity mission. *Remote Sensing of Environment*, 122:11,21, Jul 2012.
- [Jac09] Adam Jacobs. The pathologies of big data. *Communications of the ACM*, 52(8):36, August 2009.
- [Lan01] Doug Laney. 3d data management: Controlling data volume, velocity and variety. *Application Delivery Strategies published by META Group Inc.*, Feb 2001.
- [Mar06] Alex Martelli. *Python in a Nutshell. A Desktop Quick Reference*. O'Reilly, second edition edition, 2006.
- [MH13] ABM Moniruzzaman and Syed Akhter Hossain. Nosql database: New era of databases for big data analytics-classification, characteristics and comparison. *arXiv preprint arXiv:1307.0191*, 2013.
- [MSWI04] B.L. Markham, J.C. Storey, D.L. Williams, and J.R. Irons. Landsat sensor performance: history and current status. *IEEE Transactions on Geoscience and Remote Sensing*, 42(12):2691,2694, Dec 2004.
- [Sei85] Charles L Seitz. The cosmic cube. *Communications of the ACM*, 28(1):22–33, 1985.
- [TW12] Arthur Trew and Greg Wilson. *Past, present, parallel: a survey of available parallel computer systems*. Springer Science & Business Media, 2012.
- [WB72] William A Wulf and C Gordon Bell. C. mmp: a multi-mini-processor. In *Proceedings of the December 5-7, 1972, fall joint computer conference, part II*, pages 765–777. ACM, 1972.
- [WK09] Daniel Warneke and Odej Kao. Nephele: Efficient parallel data processing in the cloud. In *Proceedings of the 2Nd Workshop on Many-Task Computing on Grids and Supercomputers*, MTAGS '09, pages 8:1–8:10, New York, NY, USA, 2009. ACM.

- [YAJEA⁺00] Donald G. York, J. Adelman, Jr. John E. Anderson, Scott F. Anderson, James Annis, Neta A. Bahcall, J. A. Bakken, Robert Barkhouser, Steven Bastian, Eileen Berman, William N. Boroski, Steve Bracker, Charlie Briegel, John W. Briggs, J. Brinkmann, Robert Brunner, Scott Burles, Larry Carey, Michael A. Carr, Francisco J. Castander, Bing Chen, Patrick L. Colestock, A. J. Connolly, J. H. Crocker, Istvan Csabai, Paul C. Czarapata, John Eric Davis, Mamoru Doi, Tom Dombeck, Daniel Eisenstein, Nancy Ellman, Brian R. Elms, Michael L. Evans, Xiaohui Fan, Glenn R. Federwitz, Larry Fiscelli, Scott Friedman, Joshua A. Frieman, Masataka Fukugita, Bruce Gillespie, James E. Gunn, Vijay K. Gurbani, Ernst de Haas, Merle Haldeman, Frederick H. Harris, J. Hayes, Timothy M. Heckman, G. S. Hennessy, Robert B. Hindsley, Scott Holm, Donald J. Holmgren, Chi hao Huang, Charles Hull, Don Husby, Shin-Ichi Ichikawa, Takashi Ichikawa, Zeljko Ivezifá, Stephen Kent, Rita S. J. Kim, E. Kinney, Mark Klaene, A. N. Kleinman, S. Kleinman, G. R. Knapp, John Korienek, Richard G. Kron, Peter Z. Kunszt, D. Q. Lamb, B. Lee, R. French Leger, Siriluk Limmongkol, Carl Lindenmeyer, Daniel C. Long, Craig Loomis, Jon Loveday, Rich Lucinio, Robert H. Lupton, Bryan MacKinnon, Edward J. Mannery, P. M. Mantsch, Bruce Margon, Peregrine McGehee, Timothy A. McKay, Avery Meiksin, Aronne Merelli, David G. Monet, Jeffrey A. Munn, Vijay K. Narayanan, Thomas Nash, Eric Neilsen, Rich Neswold, Heidi Jo Newberg, R. C. Nichol, Tom Nicinski, Mario Nonino, Norio Okada, Sadanori Okamura, Jeremiah P. Ostriker, Russell Owen, A. George Pauls, John Peoples, R. L. Peterson, Donald Petravick, Jeffrey R. Pier, Adrian Pope, Ruth Pordes, Angela Prosapio, Ron Rechenmacher, Thomas R. Quinn, Gordon T. Richards, Michael W. Richmond, Claudio H. Rivetta, Constance M. Rockosi, Kurt Ruthmansdorfer, Dale Sandford, David J. Schlegel, Donald P. Schneider, Maki Sekiguchi, Gary Sergey, Kazuhiro Shimasaku, Walter A. Siegmund, Stephen Smee, J. Allyn Smith, S. Snedden, R. Stone, Chris Stoughton, Michael A. Strauss, Christopher Stubbs, Mark SubbaRao, Alexander S. Szalay, Istvan Szapudi, Gyula P. Szokoly, Anirudda R. Thakar, Christy Tremonti, Douglas L. Tucker, Alan Uomoto, Dan Vanden Berk, Michael S. Vogeley, Patrick Waddell, Shu i Wang, Masaru Watanabe, David H. Weinberg, Brian Yanny, and Naoki Yasuda. The sloan digital sky survey: Technical summary. *The Astronomical Journal*, 120(3):1579, 2000.
- [ZdP⁺12] Paul Zikopoulos, Dirk deRoos, Krishnan Parasuraman, Thomas Deutsch, James Giles, and David Corrigan. *Harness the Power of Big Data The IBM Big Data Platform*. McGraw-Hill Osborne Media, 2012.

Selbständigkeitserklärung

Ich erkläre hiermit, dass ich die vorliegende Arbeit selbständig verfasst und nur unter Verwendung der angegebenen Quellen und Hilfsmittel angefertigt habe. Weiterhin erkläre ich, eine ...arbeit in diesem Studienggebiet erstmalig einzureichen.

Berlin, den 14. Oktober 2015

.....

Statement of authorship

I declare that I completed this thesis on my own and that information which has been directly or indirectly taken from other sources has been noted as such. Neither this nor a similar work has been presented to an examination committee.

Berlin, 14th October 2015

.....